

Universidade Estadual Paulista “Júlio de Mesquita Filho”

Faculdade de Ciências e Tecnologia – FCT/UNESP

Trabalho de Modelos Lineares Generalizados

Aplicação de regressão logística na análise de fatores associados ao óbito em pacientes submetidos à cirurgia torácica no período de um ano

Disciplina: Modelos Lineares Generalizados

Professor: Guilherme Aparecido Santos Aguilar

Aluno: Vitor Marchetti Craveiro

Presidente Prudente

2026

Sumário

1	Introdução	2
1.1	Objetivo	2
1.2	Base de dados	2
1.3	Variáveis Preditoras	2
1.4	Variável Resposta	5
1.5	Base de dados definitiva pra modelagem:	5
2	Justificativa da escolha do modelo	5
3	Descrição dos passos desenvolvidos na modelagem	6
4	Desenvolvimento	8
5	Ajuste e interpretação do modelo	9
5.1	Seleção de variáveis e ajustes	9
5.2	Interpretação dos resultados	11
6	Diagnósticos do modelo	14
6.1	Ajuste global	14
6.2	Diagnóstico dos resíduos	14
6.3	Diagnóstico de influência	15
7	Conclusão	17

1 Introdução

1.1 Objetivo

O objetivo do estudo é ajustar um modelo de regressão logística para investigar quais características clínicas e pré-operatórias estão associadas à probabilidade de óbito em até um ano após cirurgia torácica realizada por causa oncológica.

1.2 Base de dados

A base de dados escolhida para realização do objetivo foi "Thoracic Surgery Data", datada em 11/12/2013 e localizada no UC Irvine Machine Learning Repository, na qual retem dados coletados respectivamente no Centro De Cirurgia Torácica de Wroclaw, referentes a pacientes que passaram por operações em decorrência ao câncer no pulmão.

Características Da Base de dados

- Área: Saúde e Medicina
- Observações: 470
- Dados Faltantes: 0
- Dados Duplicados: 0
- Variáveis preditoras: 16
- Variáveis Respostas: 1
- Tipos de dados: binários, inteiros, contínuos e de categoria

Um fator importante para se alcançar o objetivo é entender o que cada característica representada pelas variáveis preditoras significam, para isso foi realizado um estudo individual sobre cada uma.

1.3 Variaveis Preditoras

- DGN - É uma variável categórica que representa uma combinação específica de códigos ICD-10 relacionados ao câncer primário, câncer secundário e possível presença de múltiplos tumores.

Tabela 1: Distribuição dos tipos de diagnóstico na base de dados

Diagnóstico	Frequência absoluta	Frequência relativa (%)
DGN3	349	74,26
DGN2	52	11,06
DGN4	47	10,00
DGN5	15	3,19
DGN6	4	0,85
DGN8	2	0,43
DGN1	1	0,21
Total	470	100,00

Fonte: Elaborado pelo autor.

Pelo fato de "DGN3" ser a mais frequente na base de dados, foi tomada como referência para a criação das demais variáveis dummies.

- PRE6- Variável categórica que mede a condição funcional geral do paciente antes da cirurgia, essa escala chamada de Zubrod é tratada como:
 - PRZ0 - Paciente totalmente ativo, sem restrições funcionais relevantes.
 - PRZ1 - Paciente com alguma restrição para atividade física intensa, mas capaz de atividades leves.
 - PRZ2 - Paciente ambulatorio e capaz de autocuidado, mas incapaz de realizar atividades de trabalho.

Tabela 2: Distribuição do estado de desempenho Zubrod na base de dados

Estado Zubrod	Frequência absoluta	Frequência relativa (%)
PRZ1	313	66,60
PRZ0	130	27,66
PRZ2	27	5,74
Total	470	100,00

Fonte: Elaborado pelo autor.

Pelo fato de "PRZ1" ser a mais frequente na base de dados, foi tomado como referência para a criação das demais variáveis dummies.

- PRE14 - Tamanho do tumor primário:
 1. OC11 = menor tumor
 2. OC12 = tumor maior que OC11, mas menor que OC13
 3. OC13 = tumor maior que OC12, mas menor que OC14
 4. OC14 = maior tumor

Pelo fato de "OC11" representar o primeiro elemento de uma ordem natural, foi tomado como referência para a criação das demais variáveis dummies.

- PRE14 - Variável que mede a capacidade vital forçada, calculando o volume máximo de ar que o paciente consegue expirar com força depois de inspirar profundamente, por ser uma variável contínua não necessita de transformação.
- PRE5 - Variável que mede o volume expiratório forçado no primeiro segundo de uma expiração forçada, por ser uma variável contínua não necessita de transformação.
- PRE7 - Variável que indica se o paciente possuía dor antes da cirurgia ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- PRE8 - Variável que indica se o paciente apresentava tosse com sangue antes da cirurgia ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- PRE9 - Variável que indica se o paciente demonstrava falta de ar antes da cirurgia ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- PRE10 - Variável que indica se o paciente apresentava tosse antes da cirurgia ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- PRE11 - Variável que indica se o paciente possuía fraqueza antes da cirurgia ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- AGE - Variável que indica a idade do paciente logo ao entrar na cirurgia, sendo uma variável inteira não necessita de tratamento.
- PRE17 - Variável que indica se o paciente possui diabetes mellitus do tipo 2, atribuindo ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- PRE19 - Variável que indica se o paciente sofreu de um infarto do miocárdio até 6 meses antes da cirurgia, ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- PRE25 - Variável que indica se o paciente apresenta doença arterial periférica ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.

- PRE30 - Variável que indica se o paciente assume histórico de tabagismo ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.
- PRE32 - Variável que indica se o paciente apresenta asma ("True" para sim / "False" para não), como é uma variável binária ela recebe 1 para sim e 0 para não.

1.4 Variável Resposta

A variável "Risk1Yr" indica se o paciente sobreviveu ao longo do período de 1 ano após a cirurgia e tem suas frequências representadas na tabela 3.

Tabela 3: Distribuição da variável resposta (Óbito em até um ano) na base de dados

Status (1 ano pós-cirurgia)	Frequência absoluta	Frequência relativa (%)
Sobreviveu (F)	400	85,11
Faleceu (T)	70	14,89
Total	470	100,00

Fonte: Elaborado pelo autor.

Podendo-se observar uma base de dados desbalanceada e que aproximadamente 85% dos pacientes sobreviveram por pelo menos 1 ano depois da cirurgia.

1.5 Base de dados definitiva pra modelagem:

Após as alterações na base original relacionadas a tradução, por seguinte adicionou-se as variáveis dummies e se fez a substituição de F ou T para 0 ou 1 obtendo a base de dados que é realmente utilizada nesse projeto e pode ser encontrada no repositório online do autor desse projeto localizada em AplicacaoRegressaoLogisticaViesEstatisticoNaSaude:

`thoracic_surgery_data.csv` → `thoracic_surgery_variaveis_pt.csv`

`thoracic_surgery_variaveis_pt.csv` → `thoracic_surgery_base_modelo_statsmodels.csv`

2 Justificativa da escolha do modelo

Como a variável resposta deste estudo indica a ocorrência ou não de óbito em até um ano após a cirurgia torácica tem-se uma variável de natureza binária, logo a resposta pode ser representada por:

$$Y_i = \begin{cases} 1, & \text{se o paciente foi a óbito em até um ano} \\ 0, & \text{caso contrário.} \end{cases} \quad (1)$$

Dessa forma, para cada paciente i , assume-se independência e distribuição dada por:

$$Y_i \sim \text{Bernoulli}(\pi_i), \quad (2)$$

em que π_i representa a probabilidade de óbito em até um ano para o i -ésimo paciente.

Por esse motivo se decidiu através desse projeto a utilização da regressão logística, já que nesse modelo, a média da variável resposta é dada por:

$$E(Y_i) = \pi_i. \quad (3)$$

E a função de ligação utilizada é a função logit, figurada por:

$$g(\pi_i) = \log \left(\frac{\pi_i}{1 - \pi_i} \right). \quad (4)$$

Assim, a relação entre a média da resposta e o preditor linear é representada por:

$$g(\pi_i) = \eta_i, \quad (5)$$

Em que:

$$\eta_i = x_i^T \beta. \quad (6)$$

Portanto, o modelo logístico pode ser escrito como:

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = x_i^T \beta. \quad (7)$$

E ser representado na forma expandida em:

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik}. \quad (8)$$

3 Descrição dos passos desenvolvidos na modelagem

Como o objetivo principal deste estudo é investigar quais características clínicas estão associadas à probabilidade de óbito em até um ano após a cirurgia torácica, adotou-se uma abordagem de caráter explicativo, dessa forma a base completa foi utilizada no ajuste do modelo sem a divisão entre treino e teste, uma vez que o interesse central não está na construção de um classificador preditivo mas sim na estimação e interpretação das associações entre as covariáveis e a variável resposta; O primeiro modelo ajustado foi o modelo completo, contendo todas as variáveis explicativas e pode ser representado por:

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik}, \quad (9)$$

Em que π_i representa a probabilidade de óbito em até um ano para o (i) -ésimo paciente,

e $(X_1, X_2, \dots, X_k)$ representam as características clínicas consideradas no estudo, assim após o ajuste do modelo completo iniciou-se o processo de avaliação das covariáveis; Para cada coeficiente estimado, foi utilizado o teste de Wald, com o objetivo de avaliar a hipótese nula de que o coeficiente associado à covariável é igual a zero, sendo assim para cada parâmetro β_j , considerou-se o teste de hipóteses:

$$H_0 : \beta_j = 0 \quad (10)$$

VS

$$H_1 : \beta_j \neq 0. \quad (11)$$

Esse teste foi utilizado para avaliar se havia evidência estatística de associação entre cada covariável e o logaritmo da razão de chances de óbito, mantendo constantes as demais variáveis do modelo e assim as covariáveis com p-valor maior que o nível de significância adotado foram consideradas como candidatas à remoção.

No entanto, a retirada de uma covariável não foi feita apenas com base no p-valor individual encontrado pelo teste de Wald, pois para confirmar se a remoção não produzia perda relevante de ajuste, comparou-se o modelo completo com o modelo reduzido por meio da diferença de deviance entre eles.

Sob a hipótese de que o modelo reduzido é suficiente, se tem assintoticamente:

$$\Delta D \sim \chi_q^2, \quad (12)$$

em que (q) corresponde ao número de parâmetros retirados do modelo.

Portanto neste estudo, uma covariável foi removida apenas quando os dois critérios apontaram simultaneamente para sua retirada, em termos práticos, adotou-se a regra:

$$p\text{-valor}_{\beta_j} > 0,05 \quad \text{e} \quad p\text{-valor}_{\Delta D} > 0,05. \quad (13)$$

Esse procedimento foi repetido de forma sequencial até a obtenção de um modelo final composto por covariáveis interpretáveis e que não apresentassem, simultaneamente, ausência de significância individual e ausência de contribuição para o ajuste segundo a análise da deviance.

Com o modelo final definido, os coeficientes estimados foram interpretados por meio da razão de chances:

$$OR_j = \exp(\hat{\beta}_j), \quad (14)$$

Onde OR_j representa o fator multiplicativo associado à chance de óbito em até um ano, mantendo constantes as demais variáveis do modelo, entendendo que valores de OR_j maiores que 1 indicam associação com aumento da chance de óbito enquanto valores

menores que 1 indicam associação com redução dessa chance.

Por fim, após a definição do modelo final, realizou-se a análise diagnóstica com o objetivo de avaliar a adequação do ajuste e identificar possíveis observações com comportamento discrepante ou influência excessiva sobre as estimativas, assim inicialmente a qualidade global do ajuste foi analisada por meio da deviance e da estatística de Hosmer-Lemeshow, comparando os valores observados com aqueles esperados pelo modelo, para além disso foram examinados os resíduos de desvio padronizados, uma vez que eles permitem avaliar a discrepância entre as respostas observadas e as probabilidades estimadas pelo modelo logístico.

Para complementar essa análise construiu-se o gráfico normal de probabilidades com envelope, utilizado para verificar se o comportamento dos resíduos era compatível com o esperado sob o modelo ajustado e por fim foram avaliados os valores de alavancagem ($\hat{h}_{ii}$), que indicam observações potencialmente afastadas no espaço das covariáveis e medidas de influência, como a distância de Cook aproximada, com o intuito de verificar se a remoção de alguma observação poderia provocar alterações relevantes no ajuste.

Dessa forma, os diagnósticos permitiram examinar não apenas a qualidade geral do modelo, mas também a estabilidade das estimativas e a presença de possíveis pontos influentes.

4 Desenvolvimento

No desenvolvimento da modelagem, foram utilizados diferentes tipos de arquivos para organizar as etapas do projeto e permitir que os resultados gerados em uma etapa fossem reutilizados nas etapas seguintes.

- Os arquivos com extensão `.ipynb` correspondem aos notebooks do Jupyter, esses foram utilizados para organizar os códigos, as saídas, as tabelas e os gráficos de cada etapa da análise. Cada notebook representa uma parte específica do processo de modelagem, como o ajuste do modelo completo, a seleção de variáveis, a interpretação dos coeficientes e os diagnósticos do modelo final.
- Os arquivos com extensão `.csv`, sigla para *Comma-Separated Values* foram utilizados para armazenar dados em formato tabular pois esse tipo de arquivo é adequado para salvar bases de dados e tabelas de resultados, como a base tratada, o histórico da seleção das variáveis, a tabela com as razões de chances e as medidas diagnósticas.
- Os arquivos com extensão `.json`, sigla para *JavaScript Object Notation* foram utilizados para armazenar informações estruturadas, como listas de variáveis.
- Os arquivos com extensão `.pkl` são arquivos gerados pelo Python por meio do processo de serialização, conhecido como *pickle*, através disso se permitem salvar obje-

tos do Python como modelos estatísticos ajustados, para que possam ser carregados novamente em outro notebook.

Dessa forma, a organização dos arquivos permitiu separar as etapas da análise, manter os resultados intermediários armazenados e garantir maior reprodutibilidade ao processo de modelagem, toda etapa está descrita visualmente através da figura 1 e pode ser encontrada no repositório online e público do autor: `AplicacaoRegressaoLogisticaViesEstatisticoNaSaude`




Figura 1: Fluxograma dos programas e arquivos

Fonte: Elaborado pelo autor.

5 Ajuste e interpretação do modelo

5.1 Seleção de variáveis e ajustes

A seleção das variáveis preditoras foi conduzida por um procedimento backward, iniciando-se pelo modelo completo e se removendo a cada etapa apenas as variáveis que apresentaram simultaneamente p-valor superior a 0.05 no teste de Wald e também no teste da diferença de deviance, esse procedimento foi escolhido por sua coerência com a proposta explicativa do estudo uma vez que o modelo inicial contempla todas as covariáveis

consideradas relevantes e a remoção ocorre apenas quando não há evidência estatística suficiente de contribuição da variável ao ajuste.

Através dessa metodologia se obteve o seguinte resumo das variáveis que foram retiradas do modelo por não apresentar relevância estatística para o ajuste e descrição, salvo com valores na figura 2.

1. Asma
2. Infarto do miocárdio até seis meses antes da cirurgia
3. Doença arterial periférica
4. Estado de desempenho de Zubrod
5. Idade
6. Hemoptise antes da cirurgia
7. Tosse antes da cirurgia
8. Dor antes da cirurgia
9. Volume expiratório forçado em um segundo
10. Fraqueza antes da cirurgia

Resumo das remoções

iteracao	bloco_removido	n_parametros_removidos	p_valor_wald	p_valor_deviance	delta_deviance	deviance_modelo_antes	colunas_removidas
1	asma	1	0.999518	0.581850	0.303253	341.187221	asma
2	infarto_miocardio_ate_6_meses	1	0.999504	0.453798	0.561148	341.490473	infarto_miocardio_ate_6_meses
3	doenca_artorial_periferica	1	0.924999	0.924588	0.008960	342.051622	doenca_artorial_periferica
4	estado_desempenho_zubrod	2	0.664535	0.664118	0.818591	342.060582	C(estado_desempenho_zubrod, Treatment(reference=PRZ1))[(T.PRZ0), C(estado_desempenho_zubrod, Treatment(reference=PRZ1))[(T.PRZ2]
5	idade	1	0.685460	0.685771	0.163702	342.879172	idade
6	hemoptise_antes_cirurgia	1	0.629165	0.632028	0.229320	343.042875	hemoptise_antes_cirurgia
7	tosse_antes_cirurgia	1	0.371506	0.363997	0.824057	343.272195	tosse_antes_cirurgia
8	capacidade_vital_forcada	1	0.270288	0.265296	1.240907	344.096251	capacidade_vital_forcada
9	dor_antes_cirurgia	1	0.245797	0.259983	1.268849	345.337159	dor_antes_cirurgia
10	volume_expiratorio_forcado_1s	1	0.160590	0.095331	2.781962	346.606008	volume_expiratorio_forcado_1s
11	fraqueza_antes_cirurgia	1	0.105099	0.113391	2.506314	349.387970	fraqueza_antes_cirurgia

Figura 2: Retirada sequencial de variáveis não significativas para o modelo

Fonte: Elaborado pelo autor.

Após o procedimento de seleção, permaneceram no modelo final as seguintes variáveis preditoras:

- Diagnóstico, representado por 6 variáveis dummies;
- Tamanho do tumor, representado por 3 variáveis dummies;
- Dispneia antes da cirurgia, representada por 1 variável dummy;

- Diabetes mellitus tipo 2, representado por 1 variável dummy;
- Tabagismo, representado por 1 variável dummy.

Portanto o modelo final foi composto por variáveis clínicas e características associadas ao histórico do paciente, mantendo-se no ajuste apenas aquelas que não atenderam simultaneamente aos critérios de remoção definidos pelo teste de Wald e pela diferença de deviance; Deste modo o modelo final ficou da seguinte forma:

$$\begin{aligned} \log \left(\frac{\pi_i}{1 - \pi_i} \right) = & - 3.590333 - 19.567379 \times DGN1_i + 0.483186 \times DGN2_i + 0.323904 \times DGN4_i \\ & + 2.057786 \times DGN5_i - 19.133847 \times DGN6_i + 3.399590 \times DGN8_i \\ & + 0.381487 \times OC12_i + 1.204909 \times OC13_i + 1.759053 \times OC14_i \\ & + 1.142243 \times Dispneia_i + 1.028661 \times Diabetes_i + 1.210157 \times Tabagismo_i. \end{aligned}$$

E a esperança podendo ser descrita do seguinte jeito:

$$\pi_i = \left[1 + \exp \left\{ - \left(- 3.590333 - 19.567379 \times DGN1_i + 0.483186 \times DGN2_i + 0.323904 \times DGN4_i + 2.057786 \times DGN5_i - 19.133847 \times DGN6_i + 3.399590 \times DGN8_i + 0.381487 \times OC12_i + 1.204909 \times OC13_i + 1.759053 \times OC14_i + 1.142243 \times Dispneia_i + 1.028661 \times Diabetes_i + 1.210157 \times Tabagismo_i \right) \right\} \right]^{-1}.$$

5.2 Interpretação dos resultados

Após a modelagem foram extraídas informações do problema que ajudam a entender quais variáveis são mais determinantes para o óbito ou não óbito do paciente após um ano da cirurgia, esses valores estão todos na tabela 4 detalhadamente e podem ser interpretados como:

- Para a variável diagnóstico, a categoria de referência foi (DGN3). Observa-se que os pacientes classificados como (DGN5) apresentaram chance de óbito aproximadamente 7.83 vezes maior do que os pacientes classificados como (DGN3), além disso a categoria (DGN8) também apresentou aumento expressivo na chance de óbito em aproximadamente 29.95 vezes.

Uma observação importante é de que algumas categorias permaneceram na equação do modelo, mas não apresentaram significância estatística individual ao nível de 5%, um exemplo são os diagnósticos (DGN1),(DGN2),(DGN4),(DGN6).

- Para a variável relacionada ao tamanho do tumor, a categoria de referência foi (OC11). Observa-se que os pacientes classificados em (OC13) apresentaram chance de óbito cerca de 3.34 vezes maior do que aqueles em (OC11), assim como os enquadrados como (OC14) apresentam uma chance de óbito 5.81 vezes maiores em comparação com (OC11).

Novamente uma observação importante é de que algumas categorias permaneceram na equação do modelo, mas não apresentaram significância estatística individual ao nível de 5% como por exemplo a categoria (OC12).

- Para a variável relacionada à presença ou não de dispneia antes da cirurgia se observou que apresentar esse sintoma aumenta em 3.13 as chances do paciente falecer em menos de um ano após a cirurgia.
- Para a variável relacionada à presença ou não de diabetes mellitus tipo 2, conclui-se que pacientes que apresentam tal comorbidade tem chance de óbito 2.80 vezes maiores.
- Por fim, a variável que relaciona o fator tabagismo apresenta a informação de que tal característica aumenta em 3.35 vezes a chance de óbito

Tabela 4: Resultados do modelo de regressão logística em termos de coeficientes e *odds ratios*

Variável	Coef.	Erro padrão	Wald z	p -valor	IC 95% coef. inf.	IC 95% coef. sup.	OR	IC 95% OR inf.	IC 95% OR sup.	Interpretação	Significância
DGN5 vs. DGN3	2.057786	0.572920	3.591748	0.000328	0.934882	3.180689	7.828616	2.546914	24.063329	Aumento da chance de óbito	Sim, 5%
OC14 vs. OC11	1.759053	0.588889	2.987069	0.002817	0.604851	2.913255	5.806937	1.830980	18.416650	Aumento da chance de óbito	Sim, 5%
Dispneia antes da cirurgia	1.142243	0.454220	2.514733	0.011912	0.251987	2.032499	3.133790	1.286580	7.633137	Aumento da chance de óbito	Sim, 5%
Tabagismo	1.210157	0.488591	2.476828	0.013256	0.252536	2.167779	3.354012	1.287285	8.738852	Aumento da chance de óbito	Sim, 5%
Diabetes mellitus tipo 2	1.028661	0.429024	2.397677	0.016499	0.187789	1.869532	2.797316	1.206579	6.485260	Aumento da chance de óbito	Sim, 5%
DGN8 vs. DGN3	3.399590	1.507928	2.254478	0.024166	0.444106	6.355074	29.951800	1.559095	575.404681	Aumento da chance de óbito	Sim, 5%
OC13 vs. OC11	1.204909	0.603064	1.997979	0.045719	0.022925	2.386892	3.336454	1.023190	10.879627	Aumento da chance de óbito	Sim, 5%
DGN2 vs. DGN3	0.483186	0.402068	1.201752	0.229459	-0.304852	1.271223	1.621231	0.737232	3.565212	Aumento da chance de óbito	Não, 5%
OC12 vs. OC11	0.381487	0.317777	1.200487	0.229950	-0.241344	1.004317	1.464460	0.785571	2.730043	Aumento da chance de óbito	Não, 5%
DGN4 vs. DGN3	0.323904	0.456098	0.710162	0.477603	-0.570032	1.217840	1.382514	0.565507	3.379878	Aumento da chance de óbito	Não, 5%
DGN6 vs. DGN3	-19.133847	14420.173662	-0.001327	0.998941	-28282.154875	28243.887181	4.900900×10^{-9}	0.000000	∞	Redução da chance de óbito	Não, 5%
DGN1 vs. DGN3	-19.567379	29232.437996	-0.000669	0.999466	-57314.093032	57274.958274	3.176838×10^{-9}	0.000000	∞	Redução da chance de óbito	Não, 5%

Fonte: Elaborado pelo autor.

6 Diagnósticos do modelo

6.1 Ajuste global

Após o ajuste do modelo logístico final, realizou-se a análise diagnóstica com o objetivo de avaliar a qualidade do ajuste, o comportamento dos resíduos e a presença de possíveis observações influentes, tendo em vista que essa etapa é importante porque permite verificar se o modelo ajustado apresenta comportamento compatível com os dados observados e se existem observações que podem exercer influência excessiva sobre as estimativas dos parâmetros.

Inicialmente, avaliou-se o ajuste global do modelo por meio da deviance residual e do teste de Hosmer-Lemeshow.

Ao iniciar os estudos sobre a deviance residual obteve-se uma deviance igual a 351.894284, com 457 graus de liberdade, resultando em p -valor igual a 0.999916 e não fornecendo evidências estatísticas de falta de ajuste global do modelo em um nível de significância de 5%.

Por conseguinte no teste de Hosmer-Lemeshow, obteve-se estatística igual a 3.736264, com 6 graus de liberdade e p -valor igual a 0.712316, novamente demonstrando que não há evidências estatísticas há 5% para rejeitar a hipótese de bom ajuste do modelo.

6.2 Diagnóstico dos resíduos

Após a avaliação do ajuste global do modelo, analisou-se o comportamento dos resíduos de deviance padronizados.

A tabela 5 apresenta um resumo dos resíduos de deviance padronizados do modelo final.

Tabela 5: Resumo dos resíduos de deviance padronizados

Medida	Valor
Número de observações	470
Média	-0.172445
Desvio padrão	0.866996
Mínimo	-1.792323
Primeiro quartil	-0.505485
Mediana	-0.422010
Terceiro quartil	-0.282865
Máximo	2.561678
Observações com $ t_D > 2$	29
Observações com $ t_D > 3$	0

Fonte: Elaborado pelo autor.

Observa-se que os resíduos de deviance padronizados apresentaram média igual a -0.172445 e desvio padrão igual a 0.866996, sendo que o menor valor observado foi

-1.792323 enquanto o maior foi 2.561678.

Como critério descritivo, resíduos com módulo superior a 2 foram considerados pontos que merecem atenção, enquanto resíduos com módulo superior a 3 indicariam observações com discrepância mais acentuada em relação ao modelo ajustado, diante disso, nessa pesquisa foram identificadas 29 observações com $|t_D| > 2$, indicando a presença de alguns pontos com discrepância moderada, mas no entanto nenhuma observação apresentou $|t_D| > 3$, logo esse resultado sugere que embora existam observações que merecem atenção, não há evidência de resíduos extremamente discrepantes segundo esse critério.

Além da análise numérica, foi construído o gráfico normal com envelope dos resíduos de deviance padronizados, apresentado na figura 3.

Esse gráfico compara os resíduos observados com o comportamento esperado sob o modelo ajustado e quando o modelo é adequado, se espera que a maior parte dos pontos permaneça dentro dos limites do envelope, o que justamente ocorre nesse trabalho, portanto verifica-se que os resíduos apresentam comportamento compatível com o que o modelo projetou.




Figura 3: Gráfico normal com envelope dos resíduos de deviance padronizadas

Fonte: Elaborado pelo autor.

6.3 Diagnóstico de influência

Após a análise dos resíduos, avaliou-se a presença de observações potencialmente influentes no modelo final, para isso foram consideradas medidas de alavancagem e distância de Cook.

A alavancagem $\hat{h}_{ii}$ indica observações afastadas no espaço das covariáveis, enquanto a distância de Cook avalia o impacto global de cada observação sobre o ajuste.

Como o modelo final possui ($p = 13$) parâmetros e ($n = 470$) observações, foram utilizados os limites $\left(\frac{2p}{n} = 0.055319\right)$, $\left(\frac{3p}{n} = 0.082979\right)$ para alavancagem e $\left(\frac{4}{n} = 0.008511\right)$ para a distância de Cook, assim os resultados obtidos foram registrados na tabela 6.

Tabela 6: Resumo das medidas de influência do modelo final

Critério	Quantidade de observações
$\hat{h}_{ii} > 0.055319$	67
$\hat{h}_{ii} > 0.082979$	22
Distância de Cook > 0.008511	39

Fonte: Elaborado pelo autor.

Observa-se que 67 observações apresentaram valores de alavancagem superiores ao limite 0.055319, enquanto 22 ultrapassaram o limite mais restritivo 0.082979, indicando a existência de algumas observações com perfis mais afastados no espaço das covariáveis, isto é, pacientes com combinações de características menos frequentes em relação ao conjunto dos dados.

Em relação à distância de Cook, 39 observações ultrapassaram o limite 0.008511, isso sugere que algumas observações podem exercer influência moderada sobre o ajuste global do modelo, entretanto esse resultado não implica, por si só, que tais observações devam ser removidas, mas indica que elas merecem atenção na análise diagnóstica; Por esse motivo foi realizada uma análise visual apresentada na figura 4 em que nota-se que embora 39 observações estejam acima do limite de referência, apenas 5 apresentam valores consideravelmente mais elevados em comparação às demais, assim a maior parte das observações destacadas pelo critério 0.008511 apresenta influência relativamente moderada, enquanto um pequeno conjunto de pontos concentra os maiores valores da medida.




Figura 4: Gráfico das distâncias de Cook

Fonte: Elaborado pelo autor.

Diante disso optou-se por manter todas as observações no ajuste do modelo, uma vez que elas correspondem a pacientes reais e podem representar perfis clínicos relevantes, no entanto a presença desses pontos reforça a necessidade de interpretar os coeficientes do modelo com cautela, especialmente aqueles associados a categorias com menor frequência ou maior instabilidade nas estimativas.

7 Conclusão

Neste trabalho, foi ajustado um modelo de regressão logística com o objetivo de analisar fatores associados ao óbito em até um ano após cirurgia torácica, dado que a variável resposta é binária, a regressão logística mostrou-se adequada para modelar a probabilidade de ocorrência do evento de interesse e permitir a interpretação dos efeitos das covariáveis por meio das razões de chances.

A modelagem foi conduzida com uma abordagem explicativa, utilizando a base completa de dados, uma vez que o interesse principal não foi a construção de um classificador preditivo, mas sim a identificação e interpretação das características clínicas associadas ao desfecho.

A seleção de variáveis foi realizada por meio de um procedimento backward, considerando simultaneamente o teste de Wald e a diferença de deviance, tendo em vista que com esse processo, permaneceram no modelo final as variáveis diagnóstico, tamanho do tumor, dispneia antes da cirurgia, diabetes mellitus tipo 2 e tabagismo.

A interpretação das razões de chances indicou que algumas categorias de diagnóstico e tamanho do tumor apresentaram associação importante com o aumento da chance de óbito em até um ano, além disso, a presença de dispneia antes da cirurgia, diabetes mellitus tipo 2 e histórico de tabagismo também esteve associada ao aumento da chance estimada de óbito.

Os diagnósticos do modelo indicaram ajuste global satisfatório, visto que a deviance residual apresentou p-valor elevado, e o teste de Hosmer-Lemeshow também não indicou evidência estatística de falta de ajuste ao nível de significância de 5%.

A análise dos resíduos de deviance padronizados mostrou a presença de algumas observações com discrepância moderada, mas nenhuma observação apresentou resíduo em módulo superior a 3, não havendo evidência de resíduos extremamente discrepantes segundo esse critério, por outro lado, as medidas de influência indicaram a presença de algumas observações com maior alavancagem, sendo necessário abordar uma análise visual da distância de Cook a qual mostrou que, embora algumas observações ultrapassem o limite de referência, apenas um pequeno conjunto apresentou valores consideravelmente superiores aos demais, assim por fim optou-se por manter todas as observações no ajuste, uma vez que elas representam pacientes reais e podem corresponder a perfis clínicos relevantes.

De modo geral, os resultados sugerem que o modelo de regressão logística foi capaz de identificar fatores clínicos associados ao óbito em até um ano após cirurgia torácica, todavia os coeficientes devem ser interpretados com cautela, principalmente nas categorias com baixa frequência, além disso, é importante resaltar que por se tratar de uma análise observacional e explicativa, os resultados indicam associações estatísticas, não relações causais.

Portanto, conclui-se que a regressão logística se mostrou uma ferramenta adequada para investigar a relação entre características pré-operatórias e a chance de óbito em até um ano, permitindo interpretar os principais fatores associados ao desfecho e avaliar a qualidade do ajuste por meio de diagnósticos apropriados.